基于深度强化学习的云计算任务调度算法

刘肇泽

控制与计算机工程学院

2024 年 1 月 7 日

目录

强化学习基础概念

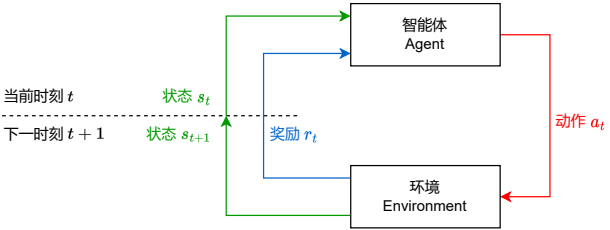

图: 智能体与环境交互

强化学习基础概念

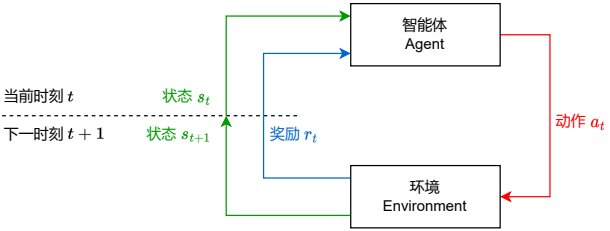

图: 智能体与环境交互

我们将当前时刻 t 及未来的奖励累加起来，记为回报 u_t ：

$$u_t = r_t + r_{t+1} + r_{t+2} + r_{t+3} + \dots$$

强化学习基础概念

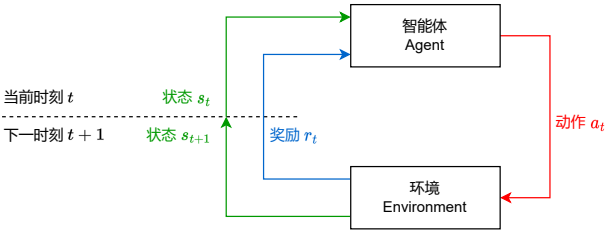

图: 智能体与环境交互

我们将当前时刻 t 及未来的奖励累加起来，记为回报 u_t ：

$$u_t = r_t + r_{t+1} + r_{t+2} + r_{t+3} + \dots$$

为了使得回报 u_t 能够收敛，我们引入折扣因子 γ ，使得未来的奖励对当前的回报的贡献逐渐减小：

$$u_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \gamma^3 r_{t+3} + \dots$$

强化学习基础概念

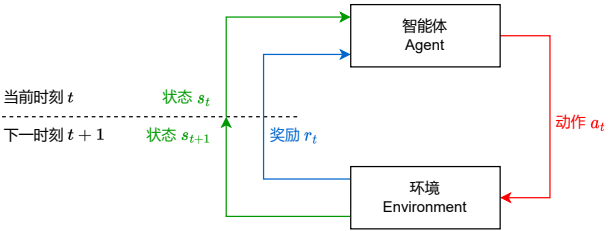

图: 智能体与环境交互

我们将当前时刻 t 及未来的奖励累加起来，记为回报 u_t ：

$$u_t = r_t + r_{t+1} + r_{t+2} + r_{t+3} + \dots$$

为了使得回报 u_t 能够收敛，我们引入折扣因子 γ ，使得未来的奖励对当前的回报的贡献逐渐减小：

$$u_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \gamma^3 r_{t+3} + \dots$$

我们的目标是最大化折扣回报 u_t 。

以超级马里奥为例

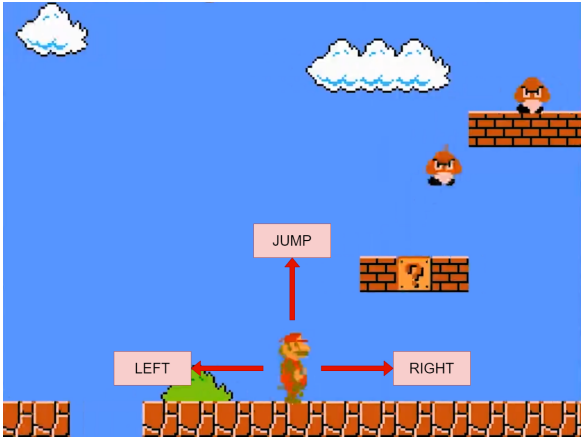

图: 超级马里奥的动作空间

以超级马里奥为例

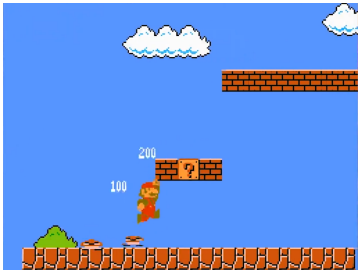

图: 击杀怪物获得奖励

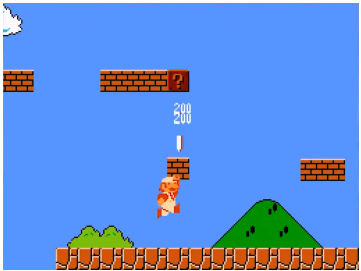

图: 收集金币获得奖励

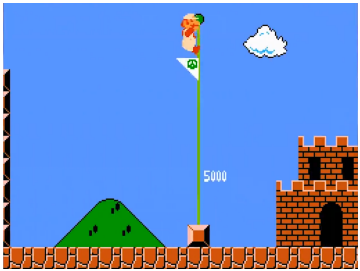

图: 到达终点获得奖励

价值学习

由于状态、动作都具有随机性，所以通常将它们设为随机变量 S 、A 。又因为智能体获得的奖励取决于当前所处环境的状态以及执行的动作，所以累计折扣回报 U_t 也是一个随机变量：

$$U_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \gamma^3 R_{t+3} + \dots$$

价值学习

由于状态、动作都具有随机性，所以通常将它们设为随机变量 S 、A 。又因为智能体获得的奖励取决于当前所处环境的状态以及执行的动作，所以累计折扣回报 U_t 也是一个随机变量：

$$U_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \gamma^3 R_{t+3} + \dots$$

在 t 时刻，我们只能得到当前环境的状态 s_t 和智能体执行的动作 a_t 。$t+1$ 时刻及之后的状态和动作都是未知的。因此我们对 $S_{t+1}, S_{t+2}, \dots$ 和 $A_{t+1}, A_{t+2}, \dots$ 求期望，以消除未知变量，记为 Q ：

$$Q(s_t, a_t) = \mathbb{E}_{S_{t+1}, A_{t+1}, S_{t+2}, A_{t+2}, \dots}[U_t | S_t = s_t, A_t = a_t]$$

其中 $Q(s_t, a_t)$ 称为动作价值函数。它可以为状态 s_t 下的动作 a_t 打分，评分越高，动作越好。

价值学习

设 Agent 的动作空间 $\mathcal{A} = \{a_1, a_2, a_3\}$ ，t 时刻观测到的状态 $S_t = s_t$ ，有：

$$Q(s_t, a_1) = 20 \qquad Q(s_t, a_2) = 100 \qquad Q(s_t, a_3) = -50$$

Agent 应选择评分最高的动作执行，即 $a_t = a_2$ 。

价值学习

设 Agent 的动作空间 $\mathcal{A} = \{a_1, a_2, a_3\}$ ，t 时刻观测到的状态 $S_t = s_t$ ，有：

$$Q(s_t, a_1) = 20 \qquad Q(s_t, a_2) = 100 \qquad Q(s_t, a_3) = -50$$

Agent 应选择评分最高的动作执行，即 $a_t = a_2$ 。
为了得到 Q 函数，我们可以使用神经网络对其进行拟合：

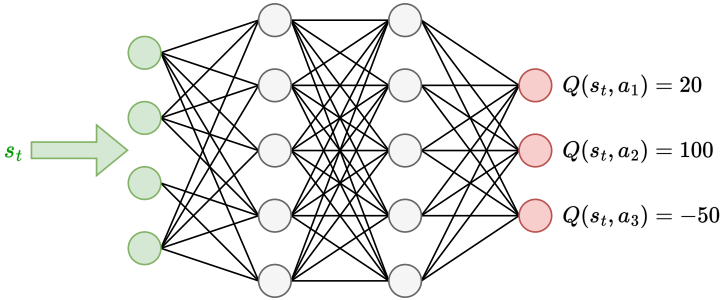

图: Deep Q-Network

云服务器任务调度模型

任务调度流程：

1. 用户提交任务
2. 任务进入任务队列
3. 任务调度器使用调度算法，根据任务属性和虚拟机状态为任务分配虚拟机

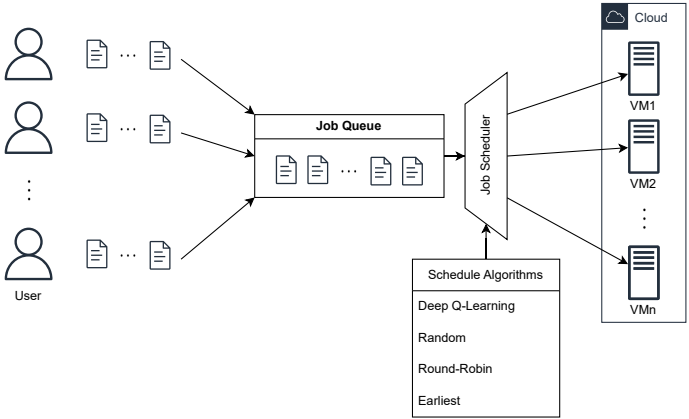

图: 云服务器任务调度模型

任务属性

对于用户提交的每个任务都具有如下属性：

- ID：任务编号
- $reqCom$：总计算量（服从正态分布）
- T_{submit}：提交时刻（泊松过程）
- $Type$：任务类型
  - 计算敏感型——编码为1
  - I/O敏感型——编码为0

对任务提交时刻的建模

假设单位时间内用户平均提交的任务数量为 λ

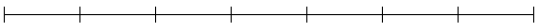

对任务提交时刻的建模

假设单位时间内用户平均提交的任务数量为 λ，那么在单位时间内均匀观察 n 次

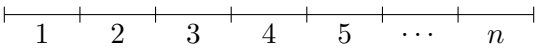

对任务提交时刻的建模

假设单位时间内用户平均提交的任务数量为 λ，那么在单位时间内均匀观察 n 次，每次观察时用户提交任务的概率为 $p = \dfrac{\lambda}{n}$。

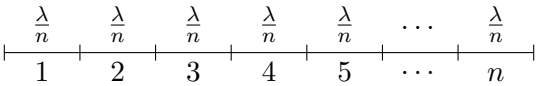

对任务提交时刻的建模

假设单位时间内用户平均提交的任务数量为 λ，那么在单位时间内均匀观察 n 次，每次观察时用户提交任务的概率为 $p = \dfrac{\lambda}{n}$。

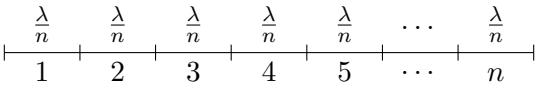

单位时间内实际提交的任务数量 X 服从二项分布 $X \sim B(n, p)$：

$$P\{X = k\} = C_n^k p^k (1-p)^{n-k}$$

对任务提交时刻的建模

当观察次数 $n \to \infty$ 时，表示在单位时间内持续观察用户提交任务的过程：

$$
\begin{aligned}
P\{X=k\} &= \lim_{n\to\infty} C_n^k p^k (1-p)^{n-k} \\
&= \lim_{n\to\infty} \frac{n(n-1)\dots(n-(k-1))}{k!} \left(\frac{\lambda}{n}\right)^k \left(1-\frac{\lambda}{n}\right)^{n-k} \\
&= \frac{\lambda^k}{k!} \lim_{n\to\infty} \frac{n(n-1)\dots(n-(k-1))}{n^k} \left(1-\frac{\lambda}{n}\right)^{-k} \left(1-\frac{\lambda}{n}\right)^{n} \\
&= \frac{\lambda^k}{k!} e^{-\lambda}
\end{aligned}
$$

对任务提交时刻的建模

当观察次数 $n \to \infty$ 时，表示在单位时间内持续观察用户提交任务的过程：

$$
\begin{aligned}
P\{X=k\} &= \lim_{n\to\infty} C_n^k p^k (1-p)^{n-k} \\
&= \lim_{n\to\infty} \frac{n(n-1)\dots(n-(k-1))}{k!} \left(\frac{\lambda}{n}\right)^k \left(1-\frac{\lambda}{n}\right)^{n-k} \\
&= \frac{\lambda^k}{k!} \lim_{n\to\infty} \frac{n(n-1)\dots(n-(k-1))}{n^k} \left(1-\frac{\lambda}{n}\right)^{-k} \left(1-\frac{\lambda}{n}\right)^{n} \\
&= \frac{\lambda^k}{k!} e^{-\lambda}
\end{aligned}
$$

此时单位时间内实际提交的任务数量 X 服从泊松分布 $X \sim P(\lambda)$ 。

对任务提交时刻的建模

记 $[0,t]$ 时间段内用户提交的任务数量为 $N(t)$，$(s,t]$ 时间段内用户提交的任务数量为 $N(s,t]=N(t)-N(s)$ 。

对任务提交时刻的建模

记 $[0,t]$ 时间段内用户提交的任务数量为 $N(t)$，$(s,t]$ 时间段内用户提交的任务数量为 $N(s,t]=N(t)-N(s)$ 。

初始时刻没有用户提交任务

对任务提交时刻的建模

记 $[0,t]$ 时间段内用户提交的任务数量为 $N(t)$，$(s,t]$ 时间段内用户提交的任务数量为 $N(s,t]=N(t)-N(s)$。

- $N(0)=0$：初始时刻没有用户提交任务

对任务提交时刻的建模

记 $[0,t]$ 时间段内用户提交的任务数量为 $N(t)$，$(s,t]$ 时间段内用户提交的任务数量为 $N(s,t]=N(t)-N(s)$。

- $N(0)=0$：初始时刻没有用户提交任务

  在互不相交的时间段内，用户提交任务的数量相互独立

对任务提交时刻的建模

记 $[0,t]$ 时间段内用户提交的任务数量为 $N(t)$，$(s,t]$ 时间段内用户提交的任务数量为 $N(s,t]=N(t)-N(s)$。

- $N(0)=0$：初始时刻没有用户提交任务
- 独立增量性：在互不相交的时间段内，用户提交任务的数量相互独立

对任务提交时刻的建模

记 $[0,t]$ 时间段内用户提交的任务数量为 $N(t)$，$(s,t]$ 时间段内用户提交的任务数量为 $N(s,t]=N(t)-N(s)$。

- $N(0)=0$：初始时刻没有用户提交任务
- 独立增量性：在互不相交的时间段内，用户提交任务的数量相互独立
  在长度相等的时间段 t 内，任务提交数量服从相同的概率分布 $P(\lambda t)$

对任务提交时刻的建模

记 $[0,t]$ 时间段内用户提交的任务数量为 $N(t)$，$(s,t]$ 时间段内用户提交的任务数量为 $N(s,t]=N(t)-N(s)$。

- $N(0)=0$：初始时刻没有用户提交任务
- 独立增量性：在互不相交的时间段内，用户提交任务的数量相互独立
- 平稳增量性：在长度相等的时间段 t 内，任务提交数量服从相同的概率分布 $P(\lambda t)$

对任务提交时刻的建模

记 $[0,t]$ 时间段内用户提交的任务数量为 $N(t)$，$(s,t]$ 时间段内用户提交的任务数量为 $N(s,t]=N(t)-N(s)$。

泊松过程

- $N(0)=0$：初始时刻没有用户提交任务
- 独立增量性：在互不相交的时间段内，用户提交任务的数量相互独立
- 平稳增量性：在长度相等的时间段 t 内，任务提交数量服从相同的概率分布 $P(\lambda t)$

对任务提交时刻的建模

记 $[0,t]$ 时间段内用户提交的任务数量为 $N(t)$，$(s,t]$ 时间段内用户提交的任务数量为 $N(s,t]=N(t)-N(s)$。

泊松过程

- $N(0)=0$：初始时刻没有用户提交任务
- 独立增量性：在互不相交的时间段内，用户提交任务的数量相互独立
- 平稳增量性：在长度相等的时间段 t 内，任务提交数量服从相同的概率分布 $P(\lambda t)$

因此 $\forall s, N(s,s+t]\sim P(\lambda t)$：

$$P\{N(s,s+t]=k\}=\frac{(\lambda t)^k}{k!}e^{-\lambda t}$$

对任务提交时刻的建模

设 W_n 为第 n 个任务提交的时刻

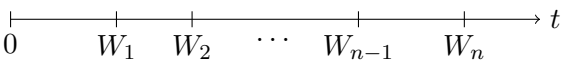

对任务提交时刻的建模

设 W_n 为第 n 个任务提交的时刻，T_n 为第 $n-1$ 个任务与第 n 个任务提交的时间间隔

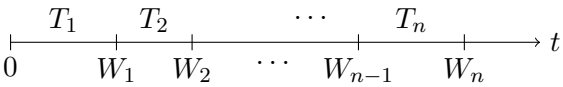

对任务提交时刻的建模

设 W_n 为第 n 个任务提交的时刻，T_n 为第 $n-1$ 个任务与第 n 个任务提交的时间间隔，则 $W_n = \sum_{i=1}^{n} T_i$ 。

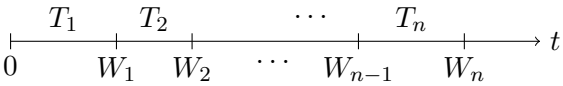

对任务提交时刻的建模

设 W_n 为第 n 个任务提交的时刻，T_n 为第 $n-1$ 个任务与第 n 个任务提交的时间间隔，则 $W_n = \sum_{i=1}^{n} T_i$ 。

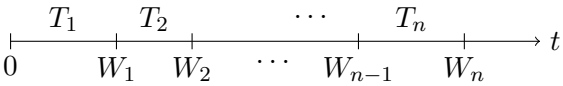

为了得到用户提交任务的时刻 T_{submit} ，只需要明确 T_n 服从的分布。

T_n 服从的分布

T_1 服从的分布

求 T_1 的分布函数：

$$F_{T_1}(t) = P\{T_1 \leqslant t\} = 1 - P\{T_1 > t\} = 1 - P\{N(0,t] = 0\} = 1 - e^{-\lambda t}$$
$$f_{T_1}(t) = F'_{T_1}(t) = \lambda e^{-\lambda t}$$

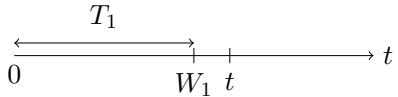

(a) $T_1 \leqslant t$

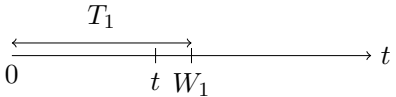

(b) $T_1 > t$

T_n 服从的分布

T_1 服从的分布

求 T_1 的分布函数：

$$F_{T_1}(t) = P\{T_1 \leqslant t\} = 1 - P\{T_1 > t\} = 1 - P\{N(0,t] = 0\} = 1 - e^{-\lambda t}$$
$$f_{T_1}(t) = F'_{T_1}(t) = \lambda e^{-\lambda t}$$

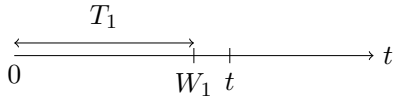

(a) $T_1 \leqslant t$

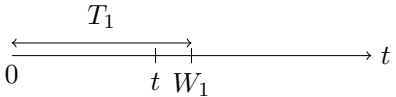

(b) $T_1 > t$

T_1 服从指数分布：$T_1 \sim E(\lambda)$ 。

T_n 服从的分布

T_2 服从的分布

求 T_2 的分布函数（假设在任意的 s 时刻，第一个任务已经提交）：

$$
\begin{aligned}
F_{T_2}(t) &= P\{T_2 \leqslant t\} = 1 - P\{T_2 > t\} \\
&= 1 - P\{N(s, s+t] = 0 | N(0, s] = 1\} \\
&= 1 - P\{N(s, s+t] = 0\} \quad (0, s]\text{与}(s, s+t]\text{两时间段互不相交，相互独立} \\
&= 1 - e^{-\lambda t}
\end{aligned}
$$

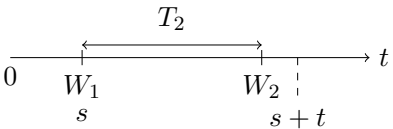

(a) $T_2 \leqslant t$

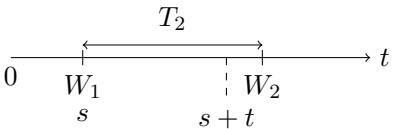

(b) $T_2 > t$

T_n 服从的分布

T_2 服从的分布

求 T_2 的分布函数（假设在任意的 s 时刻，第一个任务已经提交）：

$$
\begin{aligned}
F_{T_2}(t) &= P\{T_2 \leqslant t\} = 1 - P\{T_2 > t\} \\
&= 1 - P\{N(s, s+t] = 0 | N(0, s] = 1\} \\
&= 1 - P\{N(s, s+t] = 0\} \quad (0, s]\text{与}(s, s+t]\text{两时间段互不相交，相互独立} \\
&= 1 - e^{-\lambda t}
\end{aligned}
$$

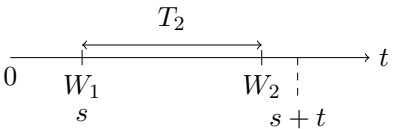

(a) $T_2 \leqslant t$

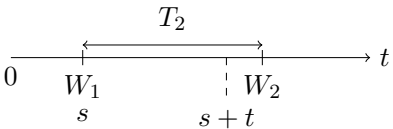

(b) $T_2 > t$

以此类推，$T_2, \ldots, T_n$ 均服从参数为 λ 的指数分布。

任务提交时间序列和总计算量

因为 $T_n \sim E(\lambda)$，所以代码中对参数为 λ 的指数分布进行采样即可得到任务提交的时间间隔。将时间间隔累加，即可得到任务提交的时间序列，对应 T_{submit}。总计算量 $reqCom$ 通过正态分布采样。

```
# 任务提交的时间间隔
submit_interval = np.random.exponential(1.0 / self.job_lambda, self.num_jobs)
# 任务的总计算量
jobs_length = np.random.normal(self.job_len_mean, self.job_len_std, self.num_jobs)

submit_time = 0
for id in range(self.num_jobs):
    submit_time += submit_interval[id]  # 累加时间间隔得到任务提交的时刻
    self.workload.append(
        Job(
            id,
            0 if np.random.random() < self.job_type_ratio else 1,
            submit_time,
            jobs_length[id],
        )
    )
```

虚拟机属性

每个虚拟机具有如下属性：

- vID：虚拟机编号
- $vCom$：单核计算速度
- $vAcc$：多核加速系数
- T_{idle}：虚拟机处理完最后一个任务的时刻
- $vType$：虚拟机类型
  - 高性能计算——编码为1
  - 高性能I/O——编码为0
- vSC：虚拟机启动开销
- vEC：虚拟机运行开销

任务在虚拟机中的执行过程

当一个任务在 T_{submit} 时刻提交给一个虚拟机时，可以得到该任务的等待时间：

$$T_{wait} = \max\{T_{idle} - T_{submit}, 0\}$$

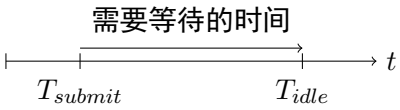

(a) $T_{idle} > T_{submit}$

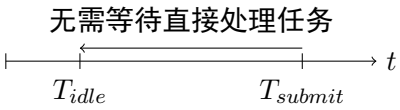

(b) $T_{idle} \leqslant T_{submit}$

任务在虚拟机中的执行过程

当一个任务在 T_{submit} 时刻提交给一个虚拟机时，可以得到该任务的等待时间：

$$T_{wait} = \max\{T_{idle} - T_{submit}, 0\}$$

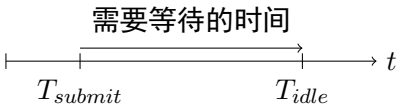

(a) $T_{idle} > T_{submit}$

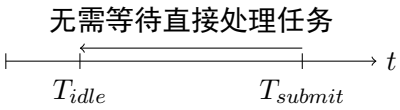

(b) $T_{idle} \leqslant T_{submit}$

当虚拟机开始执行任务时，任务的执行时间：

$$T_{exe} = \frac{Type \oplus vType + 1}{2} \cdot \frac{reqCom}{vCom \cdot vAcc}$$

任务在虚拟机中的执行过程

当一个任务在 T_{submit} 时刻提交给一个虚拟机时，可以得到该任务的等待时间：

$$T_{wait} = \max\{T_{idle} - T_{submit}, 0\}$$

(a) $T_{idle} > T_{submit}$　　(b) $T_{idle} \leqslant T_{submit}$

当虚拟机开始执行任务时，任务的执行时间：

$$T_{exe} = \frac{Type \oplus vType + 1}{2} \cdot \frac{reqCom}{vCom \cdot vAcc}$$

任务执行结束后，虚拟机的 T_{idle} 更新为 $T_{submit} + T_{exe}$ 。

优化目标

- 任务响应时间：$T_{rep} = T_{wait} + T_{exe}$
- 虚拟机费用：$cost = vSC + vEC \cdot T_{exe}$

Deep Q-Network 结构

代码中配置了 10 台虚拟机，输入状态 s_t 为当前提交任务的类型和以及提交到每台虚拟机时需要等待的时间：

$$s_t = \left[Type, T_{wait}^{(1)}, T_{wait}^{(2)}, \ldots, T_{wait}^{(10)}\right]^T$$

DQN输出在当前状态 s_t 下，对分配到每台虚拟机的总共 10 个动作的评分。

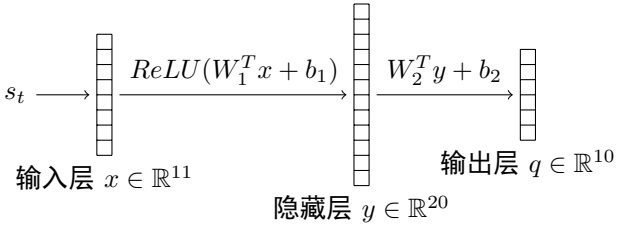

其中两层全连接层的参数：$W_1 \in \mathbb{R}^{11\times20}$, $b_1 \in \mathbb{R}^{20}$, $W_2 \in \mathbb{R}^{20\times10}$, $b_2 \in \mathbb{R}^{10}$ 。

Deep Q-Network 训练方法

奖励函数：$reward = (1 + e^{\xi - cost}) \cdot \frac{T_{exe}}{T_{rep}}$，其中 ξ 为超参数。

Deep Q-Network 训练方法

奖励函数：$reward = (1 + e^{\xi - cost}) \cdot \frac{T_{exe}}{T_{rep}}$，其中 ξ 为超参数。

- ϵ-greedy：以 ϵ 的概率随机决策，以 $1 - \epsilon$ 的概率使用DQN决策。随机决策可以探索DQN没有学到的状态，每次学习后减小 ϵ 。

Deep Q-Network 训练方法

奖励函数：$reward = (1 + e^{\xi - cost}) \cdot \frac{T_{exe}}{T_{rep}}$，其中 ξ 为超参数。

- ϵ-greedy：以 ϵ 的概率随机决策，以 $1 - \epsilon$ 的概率使用DQN决策。随机决策可以探索DQN没有学到的状态，每次学习后减小 ϵ 。
- experience replay：将过去的决策轨迹 (s_t, a_t, r_t, s_{t+1}) 存入replay memory中。DQN每次学习时从replay memory中随机选取一组样本用来更新参数，以消除学习连续样本所带来的相关性。

Deep Q-Network 训练方法

奖励函数：$reward = (1 + e^{\xi - cost}) \cdot \frac{T_{exe}}{T_{rep}}$，其中 ξ 为超参数。

- ϵ-greedy：以 ϵ 的概率随机决策，以 $1 - \epsilon$ 的概率使用DQN决策。随机决策可以探索DQN没有学到的状态，每次学习后减小 ϵ 。
- experience replay：将过去的决策轨迹 (s_t, a_t, r_t, s_{t+1}) 存入replay memory中。DQN每次学习时从replay memory中随机选取一组样本用来更新参数，以消除学习连续样本所带来的相关性。
- fixed Q-target：DQN训练时需要将 s_t 和 s_{t+1} 都输入网络中。如果仅使用一个网络，更新网络参数的操作会使 s_t 和 s_{t+1} 的输出向相同的方向移动。通过引入参数相对固定的 target 网络用来接收 s_{t+1} 的输入后，固定了参数更新的目标，加快了收敛速度。

Deep Q-Network 学习流程

确定环境参数：

- 任务：
  - 任务提交速度 $\lambda = 20$
  - 任务类型比例 CPU : I/O $= 1 : 1$
  - 任务平均总计算量 $\mu = 500$
  - 任务总计算量的标准差 $\sigma = 20$
  - 任务提交总数 500
- 虚拟机：
  - 虚拟机类型（5台计算型，5台I/O型）$[0, 0, 0, 0, 0, 1, 1, 1, 1, 1]$
  - 虚拟机费用 $cost = [1, 1, 2, 2, 4, 1, 1, 2, 2, 4]$
  - 单核计算速度 $vCom = 1000$
  - 多核加速系数 $vAcc = [1, 1, 1.1, 1.1, 1.2, 1, 1, 1.1, 1.1, 1.2]$

Deep Q-Network 学习流程

确定DRL的超参数：

- DRL超参数：
  - ϵ-greedy $\epsilon = 1.0$ ，每次学习后减小 0.001 ，减到 0.01 时不再减小
  - replay memory size $N = 100000$
  - batch size $S = 256$
  - Q-target 网络参数更新间隔 10 步
  - 奖励函数超参数 $\xi = 1.5$
  - 学习率 $\alpha = 0.001$
  - 折扣因子 $\gamma = 0.999$

Deep Q-Network 学习流程

设定环境参数、DRL超参数，随机初始化DQN参数，赋予target网络相同的参数;
foreach *Episode* **do**
  重置环境;
  foreach *Step* **do**
    对于状态 s_t 根据 ϵ-greedy 策略得到动作 a_t;
    执行动作 a_t 后环境变为 s_{t+1} 并得到奖励 r_t;
    将轨迹 (s_t, a_t, r_t, s_{t+1}) 存入replay memory;
    if *replay memory* 样本数 $\geqslant$ *256* **then**
      从replay memory中随机抽取 256 个样本作为 batch;
      foreach *sample in batch* **do**
        将 s_t 传入Q-network得到 a_t 对应的 Q_{value};
        将 s_{t+1} 传入target-network得到输出的最大值 Q_{target};
        根据损失函数 $Loss = (Q_{value} - (r_t + \gamma \cdot Q_{target}))^2$ 使用梯度下降法更新Q-network;
      end
      if *Step % 10 = 0* **then**
        使用Q-network的参数更新target-network;
      end
      减小 ϵ;
    end
  end
end

作为Baseline的3种算法

- Random：将任务随机分配给任意一台虚拟机
- Round-Robin：将任务轮流分配给每台虚拟机
- Earliest：将任务分配给最先完成任务（即 T_{wait} 最小）的虚拟机

训练过程

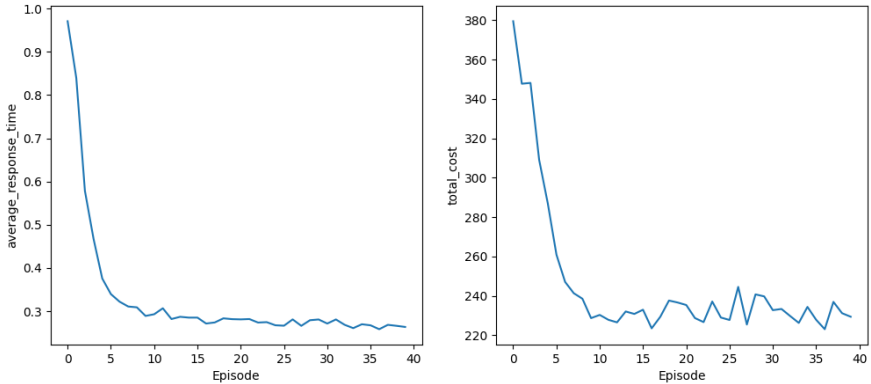

图: 训练过程中任务平均响应时间与价格的变化

DQN 与 Baseline 的对比

应对不同的任务到达速度

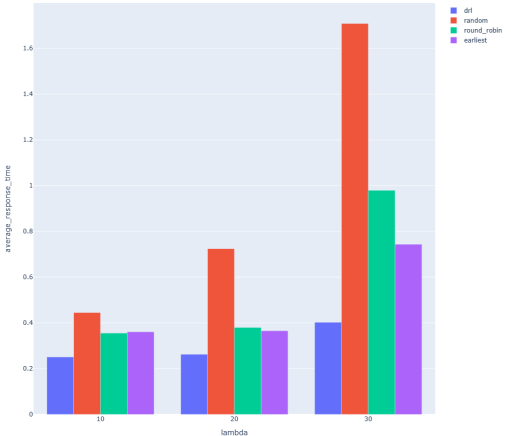

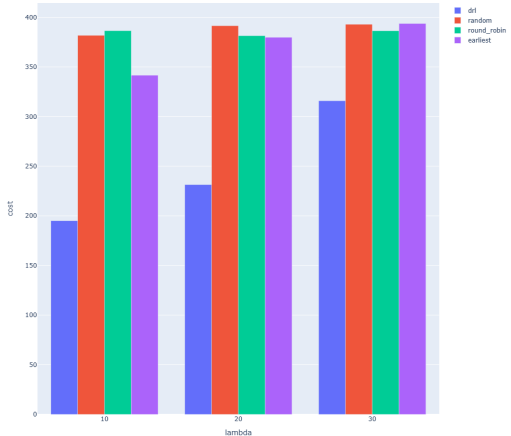

DQN 与 Baseline 的对比

应对不同的任务类型比例

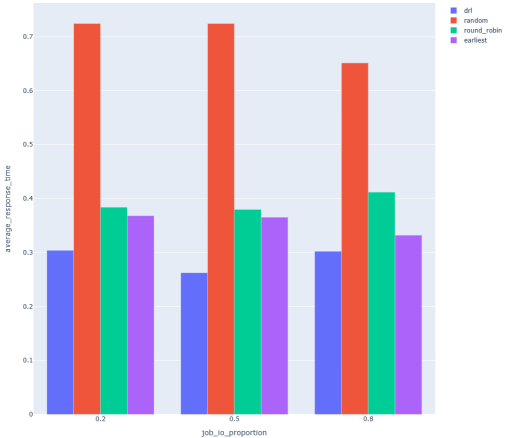

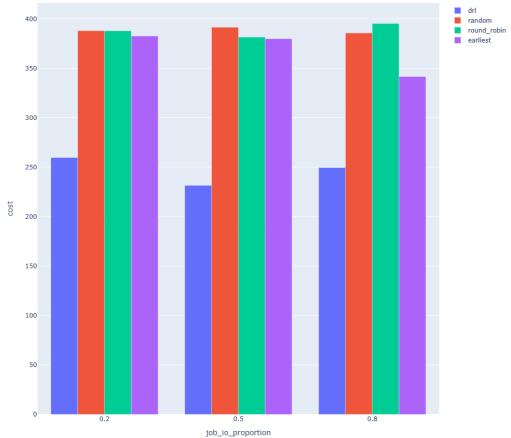

DQN 与 Baseline 的对比

应对不同的虚拟机类型比例

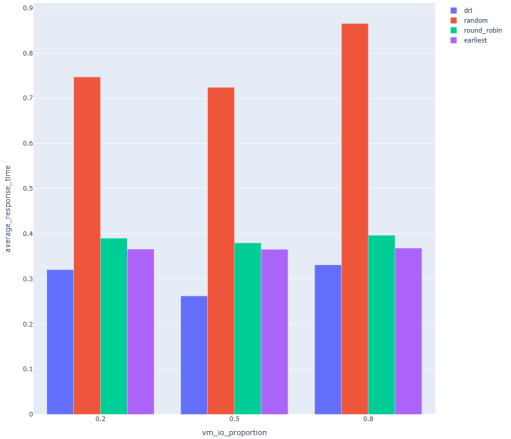

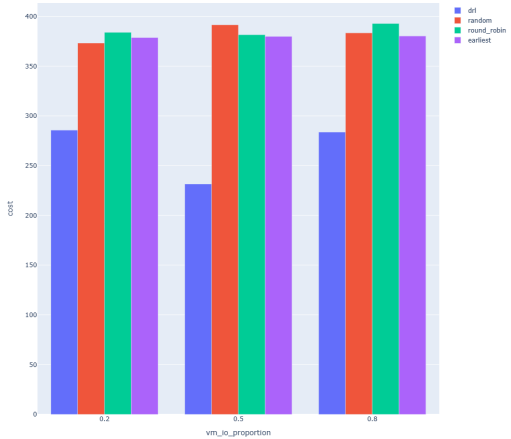

实验总结

从实验结果中可以看出，DQN 算法在任务调度方面的表现优于基准算法。在不同的环境参数下，DQN 算法都能够学习到合适的策略，使得任务的平均响应时间较短，并且使虚拟机的租金较低。

Fin.